deeplearning.ai

吴恩达 DeepLearning.ai 课程提炼笔记（1-3）神经网络和深度学习 --- 浅层神经网络

大树先生
Machine Learning、Deep Learning

1. 神经网络表示

简单神经网络示意图：

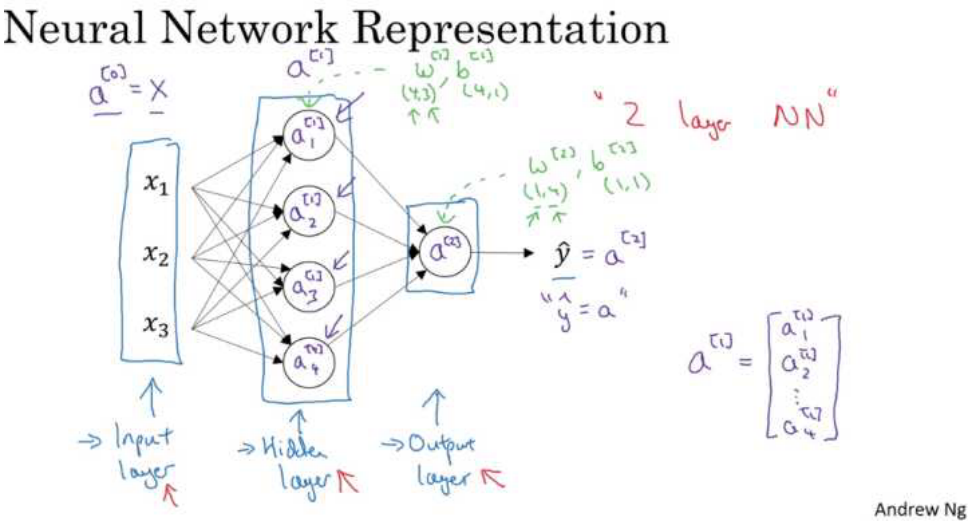

神经网络基本的结构和符号可以从上面的图中看出，这里不再复述。

主要需要注意的一点，是层与层之间参数矩阵的规格大小：

- 输入层和隐藏层之间

- $w^{[1]}->(4,3)$ ： 前面的4是隐层神经元的个数，后面的3是输入层神经元的个数；
- $b^{[1]}->(4,1)$ ： 和隐藏层的神经元个数相同；

- 隐藏层和输出层之间
  - $w^{[1]}->(1,4)$ ： 前面的1是输出层神经元的个数，后面的4是隐层神经元的个数；
  - $b^{[1]}->(1,1)$ ： 和输出层的神经元个数相同；

由上面我们可以总结出，在神经网络中，我们以相邻两层为观测对象，前面一层作为输入，后面一层作为输出，两层之间的w参数矩阵大小为 (n_{out}, n_{in}) ，b参数矩阵大小为 $(n_{out}, 1)$ ，这里是作为 $z = wX + b$ 的线性关系来说明的，在神经网络中， $w^{[i]} = w^T$ 。

在logistic regression中，一般我们都会用 (n_{in}, n_{out}) 来表示参数大小，计算使用的公式为： $z = w^T X + b$ ，要注意这两者的区别。

2. 计算神经网络的输出

除输入层之外每层的计算输出可由下图总结出：

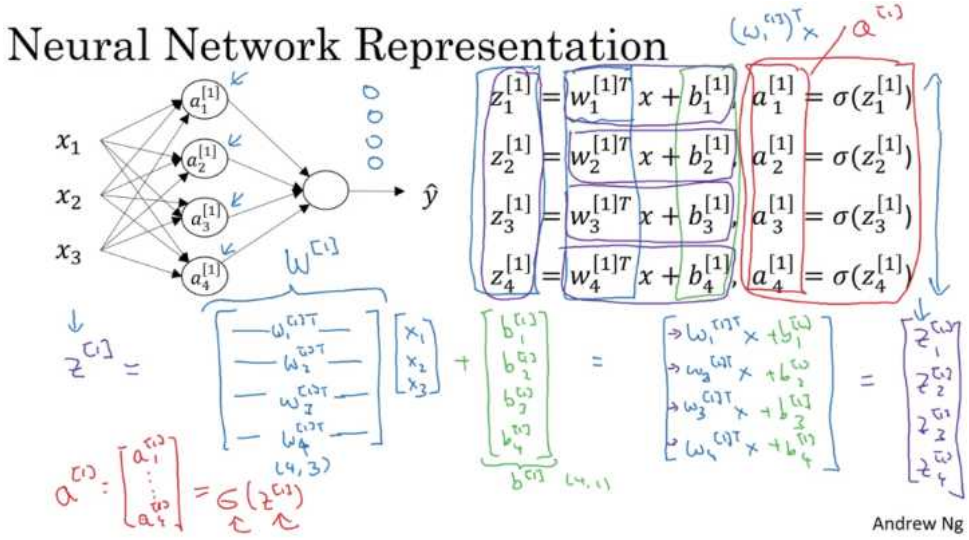

其中，每个结点都对应这两个部分的运算，z运算和a运算。 在编程中，我们使用向量化去计算神经网络的输出：

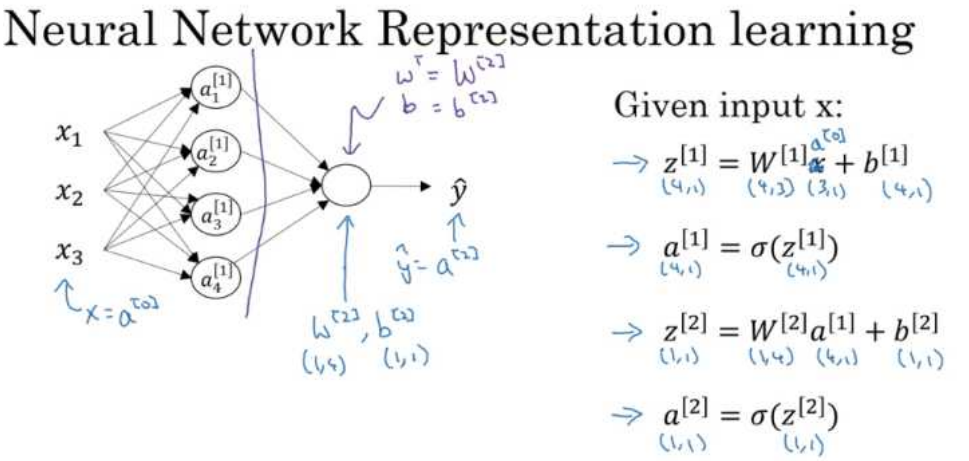

在对应图中的神经网络结构，我们只用Python代码去实现右边的四个公式即可实现神经网络的输

出计算。

3. 向量化实现

假定在m个训练样本的神经网络中，计算神经网络的输出，用向量化的方法去实现可以避免在程序中使用for循环，提高计算的速度。

下面是实现向量化的解释：

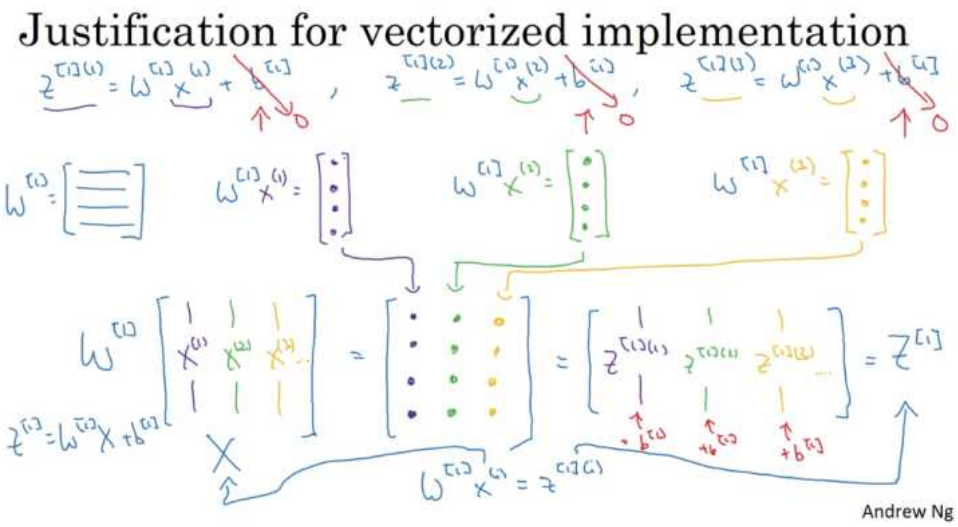

由图可以看出，在m个训练样本中，每次计算都是在重复相同的过程，均得到同样大小和结构的输出，所以利用向量化的思想将单个样本合并到一个矩阵中，其大小为 (x_n, m) ，其中 x_n 表示每个样本输入网络的神经元个数，也可以认为是单个样本的特征数，m表示训练样本的个数。

通过向量化，可以更加便捷快速地实现神经网络的计算。

4. 激活函数的选择

几种不同的激活函数 $g(x)$ ：

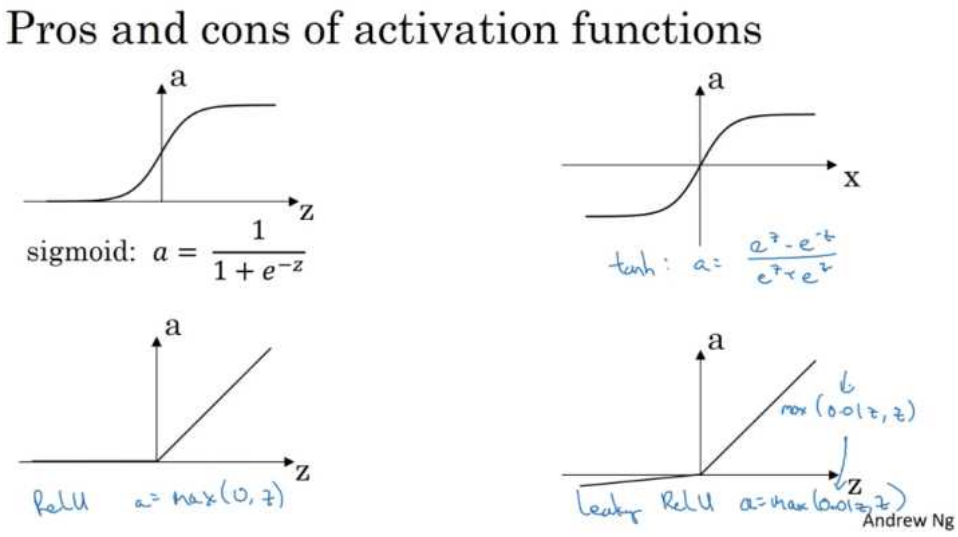

- sigmoid： $a=\frac{1}{1+e^{-z}}$
  - 导数： $a'=a(1-a)$
- tanh： $a=\frac{e^{z}-e^{-z}}{e^{z}+e^{-z}}$
  - 导数：
- ReLU（修正线性单元）： $a=\max(0,z)$
- Leaky ReLU： $a=\max(0.01z,z)$

激活函数的选择：

sigmoid函数和tanh函数比较：

- 隐藏层：tanh函数的表现要好于sigmoid函数，因为tanh取值范围为 $[-1,+1]$ ，输出分布在0值的附近，均值为0，从隐藏层到输出层数据起到了归一化（均值为0）的效果。
- 输出层：对于二分类任务的输出取值为 $\{0,1\}$ ，故一般会选择sigmoid函数。

然而sigmoid和tanh函数在当 $|z|$ 很大的时候，梯度会很小，在依据梯度的算法中，更新在后期会变得很慢。在实际应用中，要使 $|z|$ 尽可能的落在0值附近。

ReLU弥补了前两者的缺陷，当 $z>0$ 时，梯度始终为1，从而提高神经网络基于梯度算法的运算速度。然而当 $z<0$ 时，梯度一直为0，但是实际的运用中，该缺陷的影响不是很大。

Leaky ReLU保证在 $z<0$ 的时候，梯度仍然不为0。

在选择激活函数的时候，如果在不知道该选什么的时候就选择ReLU，当然也没有固定答案，要依据实际问题在交叉验证集合中进行验证分析。

5. 神经网络的梯度下降法

以本节中的浅层神经网络为例，我们给出神经网络的梯度下降法的公式。

- 参数： $W^{[1]},b^{[1]},W^{[2]},b^{[2]}$ ；
- 输入层特征向量个数： $n_x=n^{[0]}$ ；
- 隐藏层神经元个数： $n^{[1]}$ ；
- 输出层神经元个数： $n^{[2]}=1$ ；
- $W^{[1]}$ 的维度为 $(n^{[1]},n^{[0]})$ ， $b^{[1]}$ 的维度为 $(n^{[1]},1)$ ；
- $W^{[2]}$ 的维度为 $(n^{[2]},n^{[1]})$ ， $b^{[2]}$ 的维度为 $(n^{[2]},1)$ ；

下面为该例子的神经网络反向梯度下降公式（左）和其代码向量化（右）：

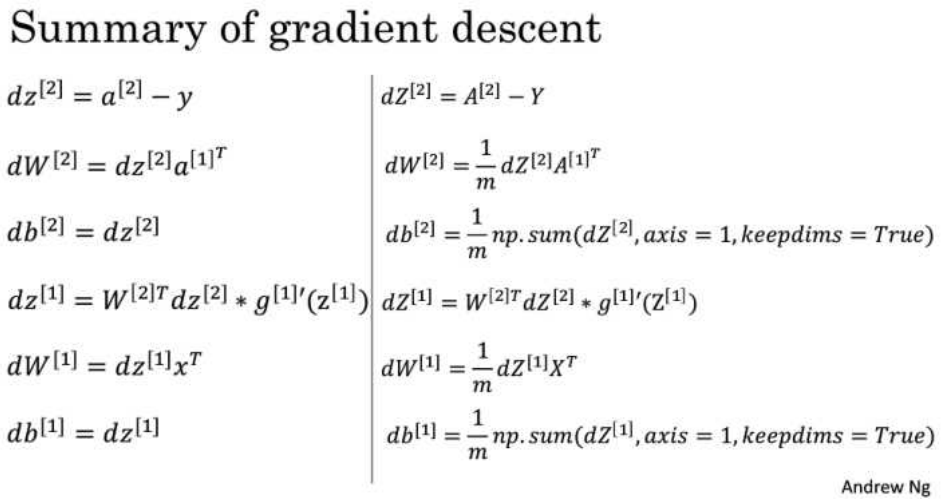

6. 随机初始化

如果在初始时，两个隐藏神经元的参数设置为相同的大小，那么两个隐藏神经元对输出单元的影响也是相同的，通过反向梯度下降去进行计算的时候，会得到同样的梯度大小，所以在经过多次迭代后，两个隐藏层单位仍然是对称的。无论设置多少个隐藏单元，其最终的影响都是相同的，那么多个隐藏神经元就没有了意义。

在初始化的时候， W 参数要进行随机初始化， b 则不存在对称性的问题它可以设置为0。 以2个输入，2个隐藏神经元为例：

```
W = np.random.rand((2,2))* 0.01
b = np.zero((2,1))
```

这里我们将W的值乘以0.01是为了尽可能使得权重W初始化为较小的值，这是因为如果使用sigmoid函数或者tanh函数作为激活函数时，W比较小，则 $Z = WX + b$ 所得的值也比较小，处在0的附近，0点区域的附近梯度较大，能够大大提高算法的更新速度。而如果W设置的太大的话，得到的梯度较小，训练过程因此会变得很慢。

ReLU和Leaky ReLU作为激活函数时，不存在这种问题，因为在大于0的时候，梯度均为1。

本文将同时更新在我的**CSDN博客**：

吴恩达Coursera深度学习课程 DeepLearning.ai 提炼笔记（1-3）

欢迎关注，一起学习一起进步哟。

编辑于 2017-11-08

深度学习（Deep Learning） 神经网络 吴恩达（Andrew Ng）

文章被以下专栏收录